ΟΙΚΟΝΟΜΙΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΑΘΗΝΩΝ

ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ

ΠΤΥΧΙΑΚΗ ΕΡΓΑΣΙΑ

«ΑΞΙΟΠΟΙΗΣΗ ΜΕΓΑΛΩΝ ΓΛΩΣΣΙΚΩΝ ΜΟΝΤΕΛΩΝ ΓΙΑ ΤΗΝ ΑΝΑΠΤΥΞΗ ΑΥΤΟΜΑΤΩΝ ΕΛΕΓΧΩΝ ΑΠΟΔΟΧΗΣ ΛΟΓΙΣΜΙΚΟΥ»

ΠΛΑΤΙΑΣ ΚΩΝΣΤΑΝΤΙΝΟΣ

ΑΡΙΘΜΟΣ ΜΗΤΡΩΟΥ: P3200157

ΕΠΙΒΛΕΠΩΝ ΚΑΘΗΓΗΤΗΣ:

ΔΙΑΜΑΝΤΙΔΗΣ ΝΙΚΟΛΑΟΣ

ΑΘΗΝΑ, ΑΥΓΟΥΣΤΟΣ 2024

Το δοκίμιο αυτό αποτελεί πτυχιακή εργασία που συντάχθηκε για το Προπτυχιακό Πρόγραμμα Σπουδών του τμήματος Πληροφορικής του ΟΙΚΟΝΟΜΙΚΟΥ ΠΑΝΕΠΙΣΤΗΜΙΟΥ ΑΘΗΝΩΝ και υποβλήθηκε τον Αύγουστο του 2024.

Ο συγγραφέας βεβαιώνει ότι το περιεχόμενο του παρόντος έργου είναι αποτέλεσμα προσωπικής εργασίας και ότι έχει γίνει η κατάλληλη αναφορά στην εργασία τρίτων -όπου κάτι τέτοιο ήταν απαραίτητο-, σύμφωνα με τους κανόνες της ακαδημαϊκής δεοντολογίας.

ΠΙΝΑΚΑΣ ΠΕΡΙΕΧΟΜΕΝΩΝ

1. ΕΙΣΑΓΩΓΗ

2. ΜΕΓΑΛΑ ΓΛΩΣΣΙΚΑ ΜΟΝΤΕΛΑ

2.1 Τι είναι ένα νευρωνικό δίκτυο και πως λειτουργεί

2.1.1 Ορισμός Νευρωνικών Δικτύων

Ξεκινώντας την συζήτηση για τα μεγάλα γλωσσικά μοντέλα και την χρήση τους, δεν θα μπορούσε να παραληφθεί η αναφορά στην βασική συνιστώσα που τα αποτελεί, το ονομαζόμενο **«νευρωνικό δίκτυο»** αλλά και τους τρόπους με τους οποίους αυτό λειτουργεί. Ένα νευρωνικό δίκτυο, όπως γίνεται αντιληπτό και από το ίδιο το όνομα, είναι ένα δίκτυο πολλών συνδεδεμένων νευρώνων, χωρισμένων σε διαφορετικά «στρώματα», όπου κάθε νευρώνας μπορεί να συσχετιστεί ως ένα αντικείμενο το οποίο παίρνει κάποιες εισόδους, εκτελεί κάποιους πολύ απλούς υπολογισμούς με αυτές και στην συνέχεια παράγει κάποια έξοδο, ένα νούμερο, το οποίο με την σειρά του περνάει σαν είσοδο στους επόμενους νευρώνες. Συγκεκριμένα, οι απλοί αυτοί υπολογισμοί είναι το άθροισμα των εισόδων που δέχθηκε πολλαπλασιασμένοι με ένα νούμερο, το ονομαζόμενο «βάρος», το οποίο μαθαίνει το νευρωνικό δίκτυο από χιλιάδες δεδομένα κατά την εκπαίδευσή του. Στην συνέχεια, αφού εφαρμοστεί ένας αριθμητικός μετασχηματισμός, το αποτέλεσμα αυτό, όπως αναφέρθηκε και προηγουμένως, μεταφέρεται στους νευρώνες του επόμενου «στρώματος» σαν είσοδο και η διαδικασία αυτή σταματά στο τελευταίο «στρώμα» νευρώνων του νευρωνικού δικτύου. Για παράδειγμα, μπορεί ένας νευρώνας να προωθεί στους νευρώνες του επόμενου στρώματος τον αριθμό μηδέν εάν οι είσοδοι που δέχτηκε ήταν αρνητικοί ή κοντά στο μηδέν, και τον αριθμό ένα στην αντίθετη περίπτωση (ονομαζόμενη «σιγμοειδής συνάρτηση ενεργοποίησης»). Συνεχίζοντας, τα μοντέλα

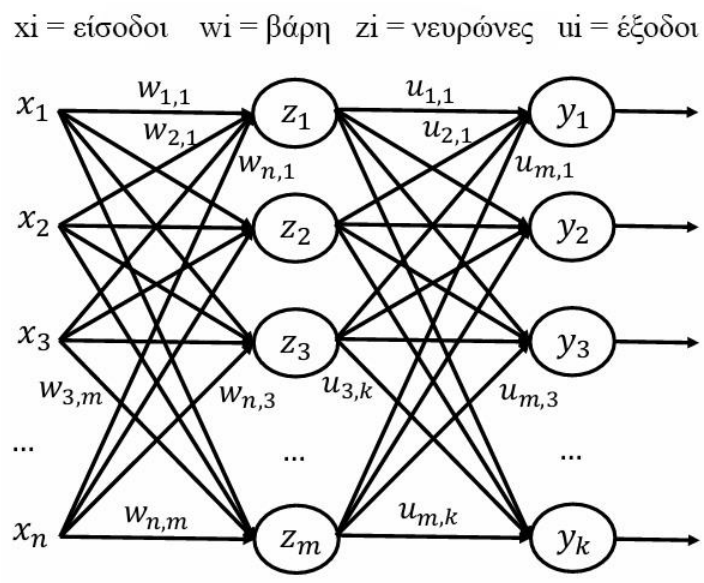

Εικόνα 1. Παράδειγμα απλού νευρωνικού δικτύου

που χρησιμοποιούν βαθιά μάθηση, χρησιμοποιούνε πολλά εκατομμύρια νευρώνες, χωρισμένα σε πολυάριθμα στρώματα με δισεκατομμύρια βάρη και πολύπλοκες διατάξεις νευρώνων, όπου όμως η βασική ιδέα παραμένει η παραπάνω. (Ανδρουτσόπουλος, 2024)

2.1.2 Ορισμός της μείωσης βαρών με καθοδική κλίση

Αυτό που κάνει τα νευρωνικά δίκτυα τόσο ενδιαφέροντα, και ως αποτέλεσμα, και την μηχανική μάθηση, είναι ότι στην ουσία, ποτέ δεν γράφεται κάποιος αλγόριθμος ο οποίος ορίζει συγκεκριμένα τι θα πρέπει να κάνει ένα νευρωνικό δίκτυο και πως θα πρέπει να παράγει αποτελέσματα, αλλά από την άλλη, γράφεται ένας αλγόριθμος ο οποίος θα μπορεί μέσω της εισαγωγής εκατομμυρίων παραδειγμάτων και δεδομένων με τις ορθές «ετικέτες» τους (το επιθυμητό δηλαδή αποτέλεσμα), να μεταβάλλει με τέτοιο τρόπο τα εκατομμύρια βάρη από τα οποία αποτελείται, ώστε να αποδίδει καλύτερα στα παραδείγματα αυτά. Τα δεδομένα αυτά ονομάζονται «δεδομένα εκπαίδευσης», τα οποία παράλληλα με τα «δεδομένα δοκιμής», τα οποία είναι παραδείγματα όπου το νευρωνικό δίκτυο δεν έχει «ξαναδεί» και τα οποία χρησιμοποιούνται για την αξιολόγηση της αποτελεσματικότητας του νευρωνικού δικτύου, αποτελούν την συνολική αξιολόγηση του συστήματος. Το πρόβλημα αυτό της μεταβολής των βαρών που καλείται να λύσει ο αλγόριθμος, καταλήγει τελικά να είναι η εύρεση του ελαχίστου μιας «συνάρτησης κόστους». Η συνάρτηση αυτή στην γενική εικόνας της υπολογίζεται με βάση τα αποτελέσματα που παράγει το νευρωνικό δίκτυο και τα επιθυμητά αποτελέσματα που έχουμε για κάθε παράδειγμα, και συνεπώς έχει μεγάλη τιμή εάν τα αποτελέσματα διαφέρουν σε μεγάλο βαθμό από τα επιθυμητά και μικρό στην αντίθετη περίπτωση. Σκοπός του αλγορίθμου είναι με βάση τον μέσο όρο όλων αυτών των τιμών κόστους για κάθε παράδειγμα, να προσπαθήσει να μεταβάλλει τις τιμές των βαρών της συνάρτησης κόστους έτσι ώστε αυτή να φτάσει σε ένα τοπικό ελάχιστο. Η τεχνική αυτή ονομάζεται «**καθοδική κλίση**» ή όπως είναι γνωστό, gradient descent, αφού προσπαθεί να βρει ένα τοπικό ελάχιστο μίας συνάρτησης με πολλές χιλιάδες

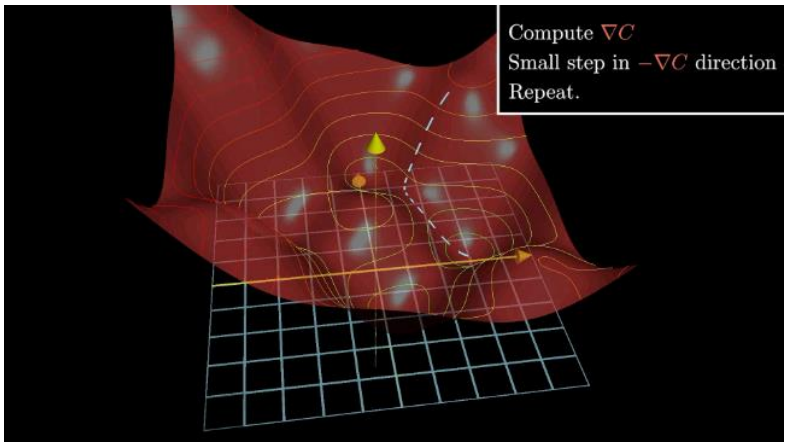

Εικόνα 2. Γεωγραφική αναπαράσταση ενός παραδείγματος Gradient descent

μεταβλητές (τις εισόδους και τα βάρη), η οποία εάν αναπαρασταθεί σε ένα διανυσματικό χώρο, έχει την εικόνα ενός «γεωγραφικού τοπίου» στο οποίο πρέπει να βρεθεί ένα τοπικό «χαμηλότερο σημείο», όπως φαίνεται και στην *Εικόνα 2*. Χρησιμοποιώντας μαθηματικές έννοιες, όλα τα παραπάνω καταλήγουν τελικά στην εύρεση του αρνητικού του «ανάδελτα ή ∇» της συνάρτησης κόστους, το οποίο δείχνει προς την πιο απότομη μείωση μίας συνάρτησης (Sanderson, 2017).

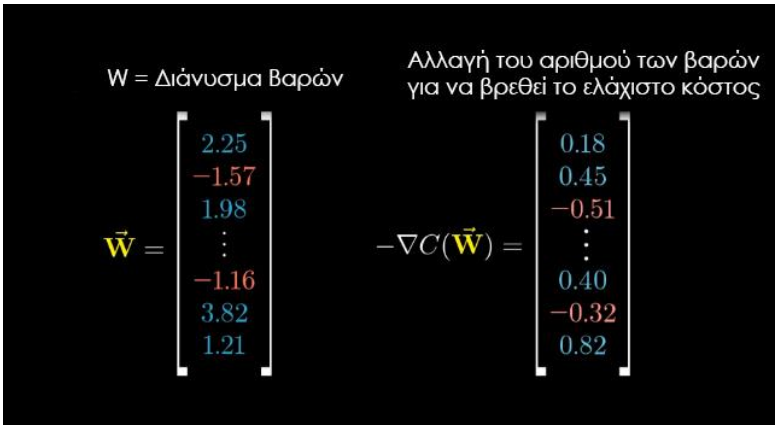

Εικόνα 3. Παράδειγμα μαθηματικής αναπαράστασης του ανάδελτα

Κατά συνέπεια, σε αυτό το σημείο θα αναφερθεί περιληπτικά ο ορισμός του αλγορίθμου που προσπαθεί να επιτύχει όλα τα παραπάνω, δηλαδή να υπολογίσει αυτό το τοπικό ελάχιστο της συνάρτησης κόστους, ο οποίος αναφέρεται ως «**αλγόριθμος ανάστροφης μετάδοσης**»

2.1.3 Ορισμός του αλγορίθμου Ανάστροφης Μετάδοσης

Όπως παρουσιάστηκε παραπάνω, ο αλγόριθμος ανάστροφης μετάδοσης είναι ένας αλγόριθμος εύρεσης ενός τοπικού ελαχίστου μέσω του υπολογισμού του αρνητικού ανάδελτα μίας

συνάρτησης κόστους. Αρχικά, ο αλγόριθμος αρχικοποιεί όλα τα βάρη του νευρωνικού δικτύου με τυχαίες μικρές τιμές και για μία δεδομένη είσοδο/παράδειγμα εκπαίδευσης, υπολογίζει το συνολικό σφάλμα/συνάρτηση κόστους στην τελική έξοδο, συγκρίνοντας την πραγματική έξοδο με την επιθυμητή έξοδο. Στην συνέχεια, το σφάλμα μεταδίδεται από την έξοδο προς την είσοδο υπολογίζοντας παράλληλα τους παραγώγους ως προς κάθε ξεχωριστό βάρος, με τον κανόνα της αλυσίδας, και κάθε βάρος ενημερώνεται ώστε να δείχνει (με την τεχνική που αναφέραμε νωρίτερα της καθοδικής κλίσης) προς την κατεύθυνση που μειώνεται το σφάλμα. Η παραπάνω διαδικασία γίνεται για κάθε παράδειγμα εκπαίδευσης που δίνεται στο νευρωνικό δίκτυο, οι οποίες ονομάζονται και «εποχές» και τελειώνει είτε μόλις το σύστημα ξεπεράσει έναν μέγιστο αριθμό εποχών, είτε εάν το συνολικό σφάλμα μειωθεί σε έναν επιθυμητό αριθμό (Ανδρουτσόπουλος, 2023).

2.2 Τι είναι ένα μεγάλο γλωσσικό μοντέλο

2.2.1 Ορισμός Μεγάλου Γλωσσικού Μοντέλου

Όπως αναφέρει και ο Ανδρουτσόπουλος(2024) με απλά λόγια, ένα μεγάλο γλωσσικό μοντέλο είναι και αυτό ένα νευρωνικό δίκτυο, το οποίο όμως παίρνει σαν εισόδους λέξεις, ή καλύτερα «tokens», σε μορφή αριθμών, τα οποία αποτελούν ίσως ένα ημιτελές κείμενο, και παράγει ως εξόδους όλες τις πιθανές λέξεις που θα μπορούσαν να είναι η επόμενη λέξη, επιλέγοντας αυτήν με την μεγαλύτερη πιθανότητα ορθότητας. Έτσι, βασιζόμενοι στο μεγάλο γλωσσικό μοντέλο, μπορούμε να πάρουμε την νέα αυτή πρόταση που παρήγαγε, να την ξαναδώσουμε σαν είσοδο και να παράγει ξανά άλλη μία επόμενη πιθανή λέξη και έτσι μετά από έναν αριθμό επαναλήψεων της διαδικασίας αυτής να παραχθεί μια ολοκληρωμένη απάντηση η οποία να βγάζει ένα νόημα.

2.2.2 Τι κάνει ένα Transformer

Πιο συγκεκριμένα, τα μεγάλα γλωσσικά μοντέλα σπάνε το κείμενο που δέχονται σαν είσοδο σε διαφορετικά tokens, τα οποία δεν είναι απαραίτητα λέξεις, αλλά μπορεί να αποτελούν και κομμάτια λέξεων, και στην συνέχεια τα αναπαριστούν σε διανύσματα. Τα διανύσματα αυτά αποτελούνται από πολλές χιλιάδες μεταβλητές και αριθμούς και τοποθετούνται σε έναν πολυδιάστατο χώρο, όπου λέξεις με παρόμοια σημασία όπως για παράδειγμα «γάτα» και

«σκύλος» βρίσκονται πολύ κοντά. Η χρήση διανυσμάτων επιτρέπει στα μεγάλα γλωσσικά μοντέλα να πραγματοποιούν μαθηματικές πράξεις που αποκαλύπτουν σχέσεις μεταξύ λέξεων. Για παράδειγμα έχει διαπιστωθεί ότι αν από το διάνυσμα της λέξης "μεγαλύτερος" αφαιρεθεί το διάνυσμα της λέξης "μεγάλος" και προστεθεί το διάνυσμα της λέξης "μικρός", το αποτέλεσμα θα είναι το διάνυσμα της λέξης "μικρότερος". Τα μεγάλα γλωσσικά μοντέλα μπορούν να αντιπροσωπεύουν τις λέξεις με διαφορετικά διανύσματα ανάλογα με τα συμφραζόμενα. Αυτό επιτυγχάνεται με τη χρήση ενός αρχιτεκτονικού μοντέλου νευρωνικού δικτύου, γνωστού ως «**transformer»,** που ενημερώνει τα διανύσματα των λέξεων μέσω πολλαπλών επιπέδων. Κάθε μεγάλο γλωσσικό μοντέλο αποτελείται από πολλά στρώματα transformers συνδεδεμένα μεταξύ τους, όπου σκοπός του κάθε ενός είναι να εμπλουτίσει με πληροφορία κάθε ένα token με βάση τα συμφραζόμενα και έτσι να αλλάξει ως προς την σωστή «κατεύθυνση» το διάνυσμα του για να έχει την ορθή σημασία που αποκαλύπτεται από τα συμφραζόμενα. Η διαδικασία αυτή επαναλαμβάνεται για κάθε transformer το οποίο προσθέτει και βελτιώνει τα διανύσματα έως και το τελικό στρώμα (Lee, 2023).

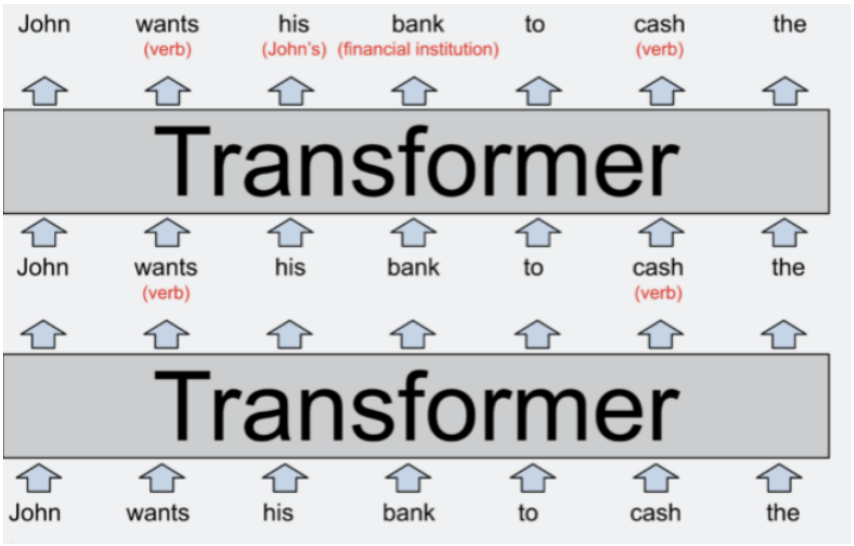

Εικόνα 4. Παράδειγμα επικοινωνίας των transformers σε ένα μεγάλο γλωσσικό μοντέλο

2.2.3 Τι είναι το Attention layer

Ένα κύριο συστατικό το οποίο αποτελεί το transformer και του επιτρέπει να εμπλουτίζει τα διανύσματα των λέξεων, είναι το **«attention layer».** Συγκεκριμένα, το συστατικό αυτό επιτρέπει στα tokens να ανταλλάσσουν πληροφορίες μεταξύ τους και να εμπλουτίζουν το ένα το άλλο έτσι

ώστε να προκύπτει η σωστή σημασία κάθε ενός. Για παράδειγμα, η λέξη «μοντέλο» έχει διαφορετική σημασία ανάλογα τα συμφραζόμενα, όπως για παράδειγμα στην πρόταση «μοντέλο μαθηματικών» και «μοντέλο του Χόλυγουντ». Η λειτουργία του attention layer είναι να γίνει ο σωστός αυτός διαχωρισμός για κάθε διαφορετικό token με βάση τις λέξεις που το περιτριγυρίζουν. Η διαδικασία αυτή επιτρέπει στα μεγάλα γλωσσικά μοντέλα να μαντεύουν σωστά την επόμενη λέξη σε κάθε κείμενο (Lee, 2023)

2.2.4 Τι είναι το Feed Forward Step

Μετά τη μεταφορά πληροφοριών ανάμεσα σε διανύσματα λέξεων από τα attention heads, το transformer αποτελείται και από ένα ακόμη συστατικό, ένα στρώμα που ονομάζεται **«feed forward»,** το οποίο «σκέφτεται» κάθε διάνυσμα λέξης και προσπαθεί να προβλέψει την επόμενη λέξη. Σε αυτό το στάδιο δεν γίνεται ανταλλαγή πληροφοριών μεταξύ των λέξεων, το στρώμα feed forward αναλύει κάθε λέξη μεμονωμένα. Ωστόσο, το στρώμα feed forward έχει πρόσβαση σε οποιαδήποτε πληροφορία αντιγράφηκε προηγουμένως από όλα τα προηγούμενα attention heads ώστε να μπορέσει αποτελεσματικότερα να προβλέψει την επόμενη λέξη (Lee, 2023).

2.3 Ιστορία και εξέλιξη των μεγάλων γλωσσικών μοντέλων

2.3.1 Το chatbot ELIZA

Ξεκινώντας μια ιστορική αναδρομή ως προς την εξέλιξη των μεγάλων γλωσσικών μοντέλων, θα αναφερθούμε στο chatbot **«ELIZA»**, το οποίο κατασκευάστηκε το 1996 και θεωρείται το πρώτο chatbot που κατασκευάστηκε από ανθρώπους με δημιουργό τον Joseph Weizenbaum στο πανεπιστήμιο του MIT. Ο τρόπος με τον οποίο λειτουργούσε το ELIZA, ήταν ότι μπορούσε να δημιουργήσει την ψευδαίσθηση συνομιλίας με την τεχνική της αναδιατύπωσης δηλώσεων των χρηστών ως

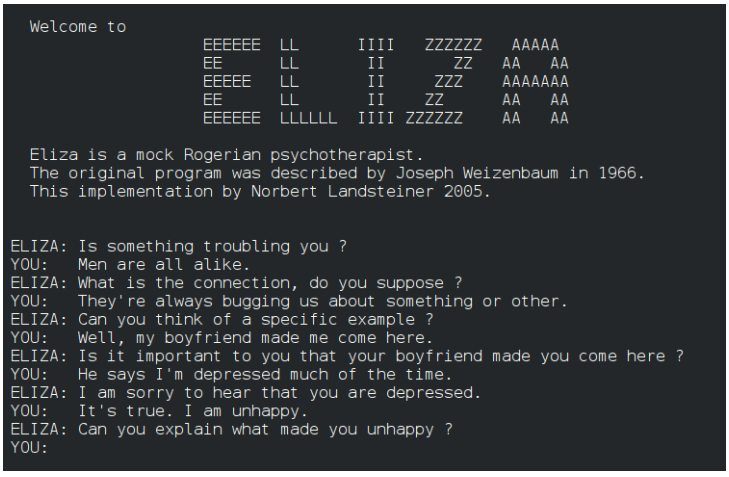

Εικόνα 5. Ένα παράδειγμα συζήτησης με το chatbot

ερωτήσεις. Εκείνη την εποχή, δημιουργήθηκαν πολλές παραλλαγές του συγκεκριμένου chatbot οι οποίες λειτουργούσαν με παρόμοιο τρόπο και μια από τις πιο γνωστές ονομάζεται «DOCTOR», η οποία ανταποκρινόταν σαν ψυχοθεραπευτής. Αυτή η αρχή έβαλε τις βάσεις για περαιτέρω έρευνα στον τομέα των chatbots και της επεξεργασίας φυσικής γλώσσας. (Pi, 2024)

2.3.2 Άνοδος των Νευρωνικών Δικτύων

Όπως αναφέρει ο Pi(2024) στο άρθρο του, προς τα τέλη του 20ου αιώνα, εμφανίστηκαν τα νευρωνικά δίκτυα, εμπνευσμένα βαθιά από τον ανθρώπινο εγκέφαλο, όπως γίνεται φανερό και από την ονομασία τους αλλά και την αρχιτεκτονική τους με διασυνδεδεμένους νευρώνες. Το 1986, αναφέρεται ως η χρονιά που έκανα την εμφάνισή τους τα «Επαναλαμβανόμενα Νευρωνικά Δίκτυα (RNN) τα οποία σε αντίθεση με τα παραδοσιακά προωθητικά νευρωνικά δίκτυα, όπου η ροή των πληροφοριών είχε μονάχα μία κατεύθυνση, μπορούσαν να θυμούνται προηγούμενες εισόδους και να απαντούν με βάση το ευρύτερο πλαίσιο και έτσι εκπαιδεύονταν να επεξεργάζονται και να μετατρέπουν μια ακολουθία δεδομένων εισόδου σε συγκεκριμένη ακολουθία δεδομένων εξόδου. Ωστόσο, τα RNN είχαν τον πολύ μεγάλο περιορισμό στο να «θυμούνται» πράγματα, κάτι σαν το σημερινό context size των μεγάλων γλωσσικών μοντέλων όπως του Chat GPT, το οποίο τα κάνει να φαίνεται σαν να «ξεχνάνε» πληροφορίες από προηγούμενα μηνύματα.

2.3.3 Δημιουργία των LSTM

Το 1997 εμφανίστηκε η Μνήμη Μακράς Βραχείας Διάρκειας (LSTM), μια εξειδικευμένη μορφή RNN που βελτίωνε το πρόβλημα της διατήρησης πληροφορίας για μεγάλες προτάσεις. Συγκεκριμένα, το εργαλείο αυτό είχε μια μοναδική αρχιτεκτονική που αποτελούνταν από πύλες εισόδου, λήθης και πύλες εξόδου. (Pi, 2024)

2.3.4 Δημιουργία Gated Recurrent Network

Το 2014, εμφανίστηκαν οι Μονάδες Επαναλαμβανόμενων Δικτύων με Πύλες (GRU), σχεδιασμένες για να επιλύουν τα ίδια προβλήματα με τα LSTM, αλλά με απλούστερη δομή. Οι GRU χρησιμοποιούσαν δύο πύλες: μια πύλη ενημέρωσης και μια πύλη επαναφοράς. (Pi, 2024)

2.3.5 Άνοδος του συστατικού Attention

Τελικά, οι τεχνολογίες RNN, LSTM και GRU φάνηκε να μην είναι τόσο καλές στην διατήρηση των συμφραζόμενων, όταν αυτό μεγαλώνει σε μεγάλο βαθμό.. Έτσι, δημιουργήθηκε ο μηχανισμός ο οποίος ονομάστηκε **«Attention»** και ο οποίος προσέφερε μία νέα οπτική στα μεγάλα γλωσσικά μοντέλα. Συγκεκριμένα, το attention επέτρεψε στο μοντέλο να «κοιτάει» πίσω σε ολόκληρο το υλικό που έχει διαθέσιμο δυναμικά, και να επιλέγει τα πιο σημαντικά κομμάτια που προσθέτουν σημασία στις υπόλοιπες προτάσεις. (Pi, 2024)

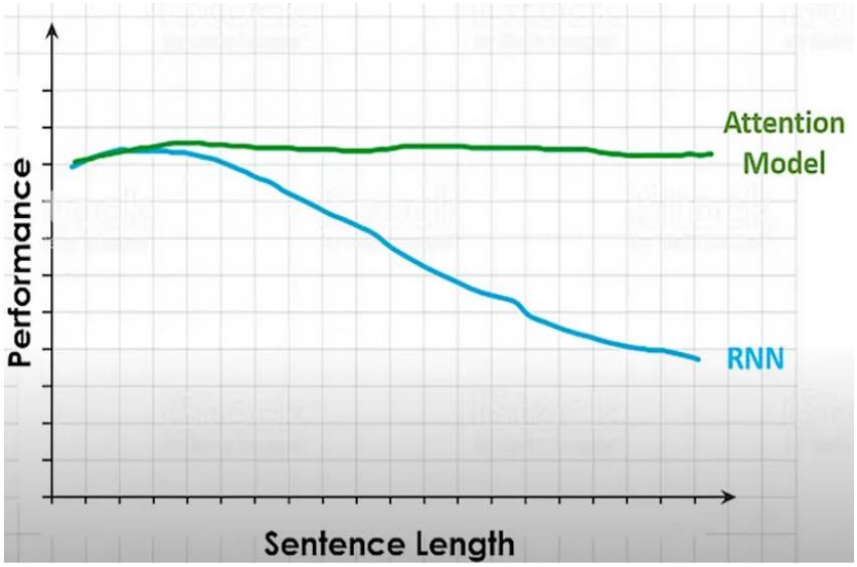

Εικόνα 6. Σύγκριση της απόδοσης Attention και RNN

2.3.6 Η εφεύρεση των Transformers

Το 2017 ήταν το έτος στο οποίο πρωτοεμφανίστηκε και η έννοια των **«Transformers»,** στο paper με όνομα «Attention is all you need» από τον Vaswani και τους συνεργάτες του στην Google. Η νέα αυτή αρχιτεκτονική, όπως εξηγήθηκε και στην προηγούμενη υποενότητα, χρησιμοποιούσε ως βασικό της εργαλείο τον μηχανισμό attention για να επεξεργαστεί τα δεδομένα εισόδου και ήταν ικανή να επεξεργάζεται ακολουθίες παράλληλα, χωρισμένη σε πολλά στρώματα, θέτοντας τα θεμέλια για μεταγενέστερα μοντέλα όπως το Chat GPT (Pi, 2024).

2.3.7 Εμφάνιση Μεγάλων Γλωσσικών Μοντέλων

Με την μεγάλη επιτυχία των transformers, το επόμενο λογικό βήμα ήταν η μεγέθυνση της κλίμακας. Αυτό ξεκίνησε με το μοντέλο BERT της Google το 2018 και συνεχίστηκε με την κυκλοφορία των GPT-2 το 2019,του GPT-3 το 2020 αλλά και των νέων εκδόσεων αυτού όπως το GPT-3.5, GPT-4 και GPT-4o (Pi, 2024).

2.4 Κύριες εφαρμογές και χρήσεις

Με την τεράστια εξέλιξη των μεγάλων γλωσσικών μοντέλων, αυτά έχουν γίνει καθημερινό εργαλείο για πολλούς ανθρώπους, γλυτώνοντας χρόνο, αφού το μέγεθός τους από δεδομένα και η πολυπλοκότητά τους επιτρέπει σε στιγμιαίες απαντήσεις χωρίς καθυστέρηση, κόστος, αφού τα περισσότερα είναι δωρεάν στην απλούστερη αλλά και πάρα πολύ αποτελεσματική μορφή τους αλλά και κόπο, αφού απαιτούν ελάχιστες γνώσεις για να τα χρησιμοποιήσεις ορθά. Όλα τα παραπάνω έχουν ωθήσει τα μεγάλα γλωσσικά μοντέλα στο να έχουν πολυάριθμες χρήσεις σε πολλούς τομείς. Όπως αναφέρει και ο Sumrak(2024), κάποια από τα δημοφιλέστερα παραδείγματα χρήσης των μεγάλων γλωσσικών μοντέλων είναι στην ανάλυση ήχου, στην δημιουργία περιεχομένου, στην υποστήριξη πελατών, στην μετάφραση γλωσσών, στην εκπαίδευση αλλά και στην κυβερνοασφάλεια.

2.4.1 Ανάλυση ήχου

Συγκεκριμένα, τα μεγάλα γλωσσικά μοντέλα έχουν αναθεωρήσει τον τρόπο με τον οποίο οι άνθρωποι χειρίζονται τα δεδομένα ήχου, αφού έχουν την δυνατότητα να ακούνε πολύωρες συζητήσεις και να παράγουν αποτελεσματικά περιλήψεις αλλά και να απαντούν ερωτήσεις σχετικά με μία πολύωρη συνάντηση. Ακόμη, μπορούν με βάση ένα μεγάλο ποσοστό κλήσεων σαν δεδομένα, να εξάγουν πολύπλοκα αποτελέσματα και συμβουλές βελτίωσης (Sumrak, 2024).

2.4.2 Δημιουργία περιεχομένου

Επιπρόσθετα, τα μεγάλα γλωσσικά μοντέλα χρησιμοποιούνται αποτελεσματικά από συγγραφείς και εμπόρους για την δημιουργία αρχικών σχεδίων(drafts), για την πρόταση διάφορων αλλαγών και για την γρήγορη εύρεση άρθρων και reports στο διαδίκτυο. Όλα τα παραπάνω επιταχύνουν με πολύ μεγάλους ρυθμούς την παραγωγικότητα των ατόμων, επιτρέποντάς τους να

επικεντρωθούν παραπάνω στο πιο απαιτητικό και δημιουργικό κομμάτι της δουλείας τους και να αφήσουν το μεγάλο γλωσσικό μοντέλο να ασχοληθεί με τα μηχανικά στοιχεία της εργασίας τους. (Sumrak, 2024).

2.4.3 Υποστήριξη πελατών

Ένας ακόμη τομέας στον οποίο τα μεγάλα γλωσσικά μοντέλα έχουν κάνει ραγδαία άνοδο και χρησιμοποιούνται κατά κόρον, είναι στην εξυπηρέτηση πελατών. Συγκεκριμένα, όπως σίγουρα έχει γίνει φανερό από πολλά άτομα, εταιρείες τηλεφωνίας, κυβερνητικές σελίδες του δημοσίου τομέα αλλά και πολύ μεγάλες επιχειρήσεις έχουν υιοθετήσει ένα μοντέλο εξυπηρέτησης πελατών μέσω των μεγάλων γλωσσικών μοντέλων, το οποίο είναι διαθέσιμο 24 ώρες την ημέρα και κάθε ημέρα της εβδομάδας χωρίς βοήθεια από κάποιο ανθρώπινο παράγοντα, το οποίο επιτρέπει την συνεχή παροχή βοήθειας σε χρήστες από όλο τον κόσμο, με πολύ λίγα έξοδα. (Sumrak, 2024).

2.4.4 Μετάφραση γλωσσών

Παράλληλα, τα μεγάλα γλωσσικά μοντέλα βοηθούν τις επιχειρήσεις στην άρση των γλωσσικών φραγμών και δίνουν την δυνατότητα στις επιχειρήσεις να προσεγγίζουν πελάτες αλλά και να προσλαμβάνουν άτομα από όλες τις χώρες του κόσμου. Αυτά τα μοντέλα προσφέρουν ακριβείς υπηρεσίες μετάφρασης σε πραγματικό χρόνο, κάνοντας ιστότοπους, εφαρμογές και ψηφιακό περιεχόμενο παγκοσμίως προσβάσιμα (Sumrak, 2024).

2.4.5 Εκπαίδευση

Ένας από τους σημαντικότερους τομείς στον οποίο γίνεται χρήση των μεγάλων γλωσσικών μοντέλων είναι αυτός της εκπαίδευσης, όπου τα μεγάλα γλωσσικά μοντέλα χρησιμοποιούνται για την παροχή εξατομικευμένης εκπαίδευσης προσαρμόζοντας το περιεχόμενο στις ατομικές ανάγκες των μαθητών, να δημιουργούν ερωτήσεις κατανόησης των μαθημάτων και να παρέχουν λεπτομερείς εξηγήσεις προσαρμοσμένες σε αυτά που οι μαθητές μαθαίνουν ή δυσκολεύονται (Sumrak, 2024).

2.4.6 Κυβερνοασφάλεια

Τέλος, τα μεγάλα γλωσσικά μοντέλα μπορούν να χρησιμοποιηθούν στην ανάλυση και την ερμηνεία μεγάλων ποσών δεδομένων κυβερνοασφάλειας, ώστε να προβλέπουν, να αναγνωρίζουν και να ανταποκρίνονται σε πιθανές απειλές ασφαλείας. Επίσης, λόγω της στοχευμένης εκπαίδευσή τους, επιτρέπουν την ταχύτερη και πιο ακριβή ανίχνευση και ανταπόκριση στις απειλές, ενισχύοντας την ασφάλεια των επιχειρήσεων (Sumrak, 2024).

2.5 Παραδείγματα Μεγάλων Γλωσσικών Μοντέλων

Ολοκληρώνοντας το κεφάλαιο 2 για τα μεγάλα γλωσσικά μοντέλα, δεν θα μπορούσε μην γίνει μία αναφορά σε κάποια από τα πιο πολυχρησιμοποιούμενα μεγάλα γλωσσικά μοντέλα και τις λειτουργίες και διαφοροποιήσεις του κάθε ενός.

2.5.1 BERT

Ξεκινώντας, το πρώτο μεγάλο γλωσσικό μοντέλο που δημιουργήθηκε ονομάστηκε **«BERT»** και αναπτύχθηκε από την Google το έτος 2018. Το BERT είναι ένα μοντέλο που χρησιμοποιεί την αρχιτεκτονική με τα πολυάριθμα στρώματα transformers συνδεδεμένα μεταξύ τους και 342 εκατομμύρια παραμέτρους για την επεξεργασία εισόδων, ενώ εκπαιδεύτηκε και σε πολλά εκατομμύρια δεδομένα για να παράγει απαντήσεις σε φυσική γλώσσα κατανοητή από τους ανθρώπους (Lutkevich, 2024).

2.5.2 GEMINI

Συνεχίζοντας με την Google, το νέο ανανεωμένο μοντέλο της ονομάστηκε **«GEMINI»**, ίδιο με το όνομα του chatbot που προσφέρει η εταιρεία στους χρήστες της. Το Gemini αποτελεί ένα πολυτροπικό μοντέλο, δηλαδή μπορεί να χειριστεί ήχο, εικόνες, βίντεο αλλά και κείμενο, σε αντίθεση με πολλά άλλα γλωσσικά μοντέλα που λειτουργούν μόνο βάση κειμένου και αποτελείται τρία «μεγέθη», το Ultra, το Pro και το Nano, από το μεγαλύτερο και πιο ικανό προς το μικρότερο και λιγότερο ικανό. Από πολλές πηγές αναφέρεται ότι το Gemini υπερτερεί σε δύναμη από το μοντέλο GPT -4 της OpenAI που θα αναφερθούμε αργότερα (Lutkevich, 2024).

2.5.3 GPT – 3

Το GPT - 3 αποτελεί το πρώτο δυνατό μοντέλο της OpenAI το οποίο παρουσιάστηκε το 2020 με περισσότερες από 175 δισεκατομμύρια παραμέτρους (το BERT έχει 342 εκατομμύρια), το οποίο χρησιμοποιεί την αρχιτεκτονική των συνδεδεμένων στρωμάτων transformers. Το GPT – 3 είναι δέκα φορές μεγαλύτερο από τον προκάτοχο του, είναι εκπαιδευμένο από εκατομμύρια δεδομένα και αποτελεί το τελευταίο μοντέλο από την σειρά μοντέλων που παρήγαγε η OpenAI, για το οποίο ήταν δημόσια γνωστός ο αριθμός των παραμέτρων που χρησιμοποιούσε (Lutkevich, 2024).

2.5.4 GPT - 3.5 και GPT – 3.5 Turbo

Το GPT – 3.5 αποτελεί την ενημερωμένη έκδοση του GPT – 3 με λιγότερες παραμέτρους αλλά πιο ποιοτικά δεδομένα εκπαίδευσης, το οποίο βρίσκεται πίσω από την λειτουργία της πλατφόρμας Chat GPT η οποία το 2023 άλλαξε ριζικά την δημοτικότητα και την χρήση των μεγάλων γλωσσικών μοντέλων προς το καλό. Το GPT – 3 είναι εκπαιδευμένο με γνώσεις μέχρι και τον Σεπτέμβρη του 2021 και δεν έχει την δυνατότητα εισχώρησης στο διαδίκτυο συγκριτικά με άλλα μεγάλα γλωσσικά μοντέλα. Παράλληλα, μια δυνατότερη έκδοση του ονομάζεται «Turbo» και χρησιμοποιείται από το πολύ γνωστό chatbot της Microsoft, το GitHub COPILOT, με σκοπό την υποβοήθηση των προγραμματιστών στην αποτελεσματικότερη παραγωγή κώδικα και την διόρθωση και εύρεση σφαλμάτων (Lutkevich, 2024).

2.5.5 GPT – 4

Το GPT- 4 αποτελεί το μεγαλύτερο μοντέλο στη σειρά GPT της OpenAI, το οποίο κυκλοφόρησε το 2023. Όπως και τα προηγούμενα, είναι ένα μοντέλο βασισμένο σε transformers. Ωστόσο, ο αριθμός των παραμέτρων του δεν έχει δημοσιοποιηθεί, αν και φήμες λένε ότι έχει πάνω από 170 **τρισεκατομμύρια**, αριθμός πολλά μεγέθη μεγαλύτερος από όλα τα προηγούμενα μοντέλα που αναφέρθηκαν. Η OpenAI περιγράφει το GPT-4 ως ένα πολυτροπικό μοντέλο(όπως και το GEMINI), πράγμα που σημαίνει ότι μπορεί να επεξεργάζεται κείμενο, ήχο και εικόνες, σε αντίθεση με τα προηγούμενα μοντέλα της OpenAI που περιορίζονταν μόνο στο κείμενο. Το GPT- 4, υποστηρίζεται ότι πλησίασε την τεχνητή γενική νοημοσύνη (AGI), που σημαίνει ότι είναι εξίσου έξυπνο ή εξυπνότερο από έναν άνθρωπο και σημαντικότερα έχει την δυνατότητα

της εύρεσης πληροφοριών από το διαδίκτυο, σε αντίθεση με το GPT – 3.5, κάτι το οποίο το κάνει ακόμη πιο δυνατό (Lutkevich, 2024).

2.5.6 GPT – 4o

Το GPT-4 Omni (GPT-4o) είναι ο διάδοχος και του GPT-4 της OpenAI και το πλέον νεότερο μεγάλο γλωσσικό μοντέλο της και προσφέρει αρκετές βελτιώσεις σε σχέση με το προηγούμενο μοντέλο. Το GPT-4o φαίνεται να δημιουργεί μια πιο φυσική ανθρώπινη αλληλεπίδραση για το Chat GPT και είναι και αυτό ένα μεγάλο πολυτροπικό μοντέλο, με την διαφορά ότι μπορεί να δει φωτογραφίες ή οθόνες και να κάνει ερωτήσεις σχετικά με αυτές κατά τη διάρκεια της αλληλεπίδρασης (Lutkevich, 2024).

3. ΜΕΓΑΛΑ ΓΛΩΣΣΙΚΑ ΜΟΝΤΕΛΑ ΣΤΗΝ ΑΝΑΠΤΥΞΗ ΛΟΓΙΣΜΙΚΟΥ

3.1 Ρόλος των μεγάλων γλωσσικών μοντέλων στην ανάπτυξη λογισμικού

3.1.1 Εισαγωγή στην έννοια των γλωσσικών μοντέλων στην ανάπτυξη λογισμικού

Όπως αναλύθηκε και παραπάνω, τα μεγάλα γλωσσικά μοντέλα είναι συστήματα τεχνητής νοημοσύνης τα οποία μπορούν με βάση κάποια συζήτηση και κάποιες ερωτήσεις ενός χρήστη, να ανταποκριθούν με απαντήσεις σε ανθρώπινη γλώσσα με μεγάλο βάθος κατανόησης των συμφραζόμενων και των αναγκών του χρήστη κάθε φορά. Έτσι, μπορούν να ενσωματωθούν με μεγάλη ευκολία σε αμέτρητους τομείς της καθημερινότητας και να εκτελέσουν αμέτρητες εργασίες με μεγάλη αποδοτικότητα και προσαρμοστικότητα. Επομένως, δεν θα μπορούσαν να μην αποτελούν ένα πολύ χρήσιμο και παραγωγικό εργαλείο και στον τομέα της ανάπτυξης λογισμικού. Ιδιαίτερα, ο εσωτερικός τρόπος λειτουργίας των μεγάλων γλωσσικών μοντέλων τα καθιστά εξαιρετικά στην υποβοήθηση πάρα πολλών έργων και στην λύση των δυσκολιών που μπορεί να προκύψουν από έναν προγραμματιστή κατά την διάρκεια της διαδικασίας της ανάπτυξης λογισμικού, αυξάνοντας έτσι σε πολύ μεγάλο βαθμό την παραγωγικότητα του, μειώνοντας τον χρόνο εκσφαλμάτωσης και συνεπώς και τον χρόνο που απαιτείται για την ολοκλήρωση ενός έργου. Όλα αυτά προκύπτουν από το γεγονός ότι τα μεγάλα γλωσσικά

μοντέλα έχουν την δυνατότητα να γράφουν, να διορθώνουν και να βελτιστοποιούν τον κώδικα πολύ πιο γρήγορα και με μεγαλύτερη ακρίβεια από ότι θα μπορούσε οποιοσδήποτε προγραμματιστής, αφού έχουν υποστεί εκπαίδευση σε δισεκατομμύρια «project» ανοιχτού κώδικα από εφαρμογές όπως το GitHub και δέχονται συνεχή ενημέρωση σε νέα κάθε ημέρα.

3.1.2 Παραδείγματα χρήσης μεγάλων γλωσσικών μοντέλων στην ανάπτυξη λογισμικού

Κάποια από τα σημαντικότερα παραδείγματα χρήσης των μεγάλων γλωσσικών μοντέλων στην ανάπτυξη λογισμικού είναι η αυτοματοποιημένη γραφή κώδικα, η ανάλυση και διόρθωση λαθών αλλά και η ανάλυση των απαιτήσεων και η μετατροπή σε τεχνικές προδιαγραφές. Ως προς τον τομέα του αυτοματοποιημένου κώδικα, τα μεγάλα γλωσσικά μοντέλα μπορούν να προτείνουν στον προγραμματιστή ολόκληρα αποσπάσματα κώδικα ή ακόμη και να γράφουν τις πλήρεις λειτουργίες ενός συστήματος, μονάχα με βάση τις περιγραφές των προγραμματιστών, ενώ μπορούν και να παρέχουν προτάσεις κώδικα και βοήθειες σε μορφή comments σε πραγματικό χρόνο, όπως στο chatbot της Microsoft, το GitHub Copilot, το οποίο αποτελεί και ένα από τα γλωσσικά μοντέλα στα οποία διεξήχθη το πείραμα της εργασίας. Στην συνέχεια, τα μεγάλα γλωσσικά μοντέλα είναι ικανά να αναγνωρίζουν με μεγάλη ευκολία και ταχύτητα σφάλματα που έχουν συμβεί κατά την διάρκεια της συγγραφής πολύ μεγάλων ποσοτήτων κώδικα, να τα αναλύουν και να περιγράφουν λύσεις με βάση πολύπλοκους τρόπους εκσφαλμάτωσης αλλά να δίνουν και τα ίδια τις διορθώσεις σε όλα τα πιθανά λάθη που έχουν εντοπιστεί. Ακόμη, μπορούν να βελτιώνουν την ποιότητα του κώδικα μέσω της αναθεώρησης σημείων όπου επιδέχονται βελτίωσης και έτσι να δημιουργείται ένα πιο ποιοτικό αποτέλεσμα από τον χρήστη. Τέλος, τα γλωσσικά μοντέλα μπορούν να διαβάζουν και να κατανοούν τα διάφορα έγγραφα απαιτήσεων, να τα διορθώνουν και να χρησιμοποιούν φυσική γλώσσα και διαγράμματα για να εξάγουν τις βασικές ανάγκες και προδιαγραφές που πρέπει να περιγραφούν στους εμπλεκόμενους ενός μεγάλου έργου.

3.2 Χρήσεις σε διάφορα στάδια της ανάπτυξης λογισμικού

3.2.1 Ανάλυση απαιτήσεων

4. ΒΙΒΛΙΟΓΡΑΦΙΑ

Lee, T. B. (2023, Ιούλιος 31). Ανάκτηση από arstechnica.com: https://arstechnica.com/science/2023/07/a-jargon-free-explanation-of-how-ai-large-language-models-work/6/

Pi, W. (2024, Μάϊος 7). *Research Graph.* Ανάκτηση από Medium: https://medium.com/@researchgraph/brief-introduction-to-the-history-of-large-language-models-llms-3c2efa517112

Sanderson, G. (2017, Οκτώβριος 16). *3blue1brown.* Ανάκτηση από 3blue1brown: https://www.3blue1brown.com/lessons/gradient-descent#another-way-to-think-about-the-gradient

Sumrak, J. (2024, Μάρτιος 11). *7 LLM use cases and applications in 2024.* Ανάκτηση από AssemblyAI: https://www.assemblyai.com/blog/llm-use-cases/

Ανδρουτσόπουλος, Ί. (2024, Φεβρουάριος). Τεχνητή Νοημοσύνη και Μεγάλα Γλωσσικά Μοντέλα. *ΟΠΑ News Εφημερίδα Οικονομικού Πανεπιστημίου Αθηνών Τεύχος 51*, σσ. 8-9.